

Estimación de densidades mediante modelos de mezcla controlados por el proceso de Dirichlet

Estudiantes:

MANUEL HERNÁNDEZ BANADIK
MARIO SIERRA GOLOMBIEVSKI

Tutor:

IGNACIO ALVAREZ-CASTRO



2 de julio de 2019

Plan

1 Aspectos preliminares

- Inferencia Bayesiana
- Modelos de mezcla

2 Estimación de un distribución

- Modelo Dirichlet-Multinomial
- Medida de probabilidad aleatoria
- Proceso de Dirichlet: Definición
- Stick-Breaking
- Estimación de una distribución

3 Modelos de mezcla controlados por proceso de Dirichlet

- Formulación del modelo
- Implementación del estimador

4 Estudio de simulación

5 Aspectos computacionales

Inferencia Bayesiana

Supongamos que se observan los datos $\mathbf{y} = (y_1, \dots, y_n)$.

- $\mathbf{y} \sim f(\mathbf{y}|\theta)$ es lo que se denomina **modelo para los datos**

Inferencia Bayesiana

Supongamos que se observan los datos $\mathbf{y} = (y_1, \dots, y_n)$.

- $\mathbf{y} \sim f(\mathbf{y}|\theta)$ es lo que se denomina **modelo para los datos**
- $f(\theta)$ es la **distribución previa** para el parámetro

Inferencia Bayesiana

Supongamos que se observan los datos $\mathbf{y} = (y_1, \dots, y_n)$.

- $\mathbf{y} \sim f(\mathbf{y}|\theta)$ es lo que se denomina **modelo para los datos**
- $f(\theta)$ es la **distribución previa** para el parámetro
- Por el **Teorema de Bayes** se obtiene la **distribución posterior**:

$$f(\theta|\mathbf{y}) = \frac{f(\mathbf{y}|\theta)f(\theta)}{f(\mathbf{y})} = \frac{f(\mathbf{y}|\theta)f(\theta)}{\int f(\mathbf{y}|\theta)f(\theta)d\theta} \propto f(\mathbf{y}|\theta)f(\theta)$$

Inferencia Bayesiana

Supongamos que se observan los datos $\mathbf{y} = (y_1, \dots, y_n)$.

- $\mathbf{y} \sim f(\mathbf{y}|\theta)$ es lo que se denomina **modelo para los datos**
- $f(\theta)$ es la **distribución previa** para el parámetro
- Por el **Teorema de Bayes** se obtiene la **distribución posterior**:

$$f(\theta|\mathbf{y}) = \frac{f(\mathbf{y}|\theta)f(\theta)}{f(\mathbf{y})} = \frac{f(\mathbf{y}|\theta)f(\theta)}{\int f(\mathbf{y}|\theta)f(\theta)d\theta} \propto f(\mathbf{y}|\theta)f(\theta)$$

En general, esta no se puede calcular analíticamente, siendo necesario recurrir a métodos computacionales para estimarla.

Inferencia Bayesiana

Supongamos que se observan los datos $\mathbf{y} = (y_1, \dots, y_n)$.

- $\mathbf{y} \sim f(\mathbf{y}|\theta)$ es lo que se denomina **modelo para los datos**
- $f(\theta)$ es la **distribución previa** para el parámetro
- Por el **Teorema de Bayes** se obtiene la **distribución posterior**:


$$f(\theta|\mathbf{y}) = \frac{f(\mathbf{y}|\theta)f(\theta)}{f(\mathbf{y})} = \frac{f(\mathbf{y}|\theta)f(\theta)}{\int f(\mathbf{y}|\theta)f(\theta)d\theta} \propto f(\mathbf{y}|\theta)f(\theta)$$

En general, esta no se puede calcular analíticamente, siendo necesario recurrir a métodos computacionales para estimarla.

Cuando $f(\theta)$ y $f(\theta|\mathbf{y})$ pertenecen a la misma familia, se dice que la distribución previa es conjugada natural.


Modelos de mezcla

$$f(x) = 0.6 \times \phi(x; 170, 1) + 0.4 \times \phi(x; 180, 1)$$



Modelos de mezcla

$$f(x) = 0.6 \times \phi(x; 170, 1) + 0.4 \times \phi(x; 180, 1)$$




Un modelo de mezcla finito tiene la forma:

$$f(x) = \pi_1 f_1(x|\theta_1) + \cdots + \pi_H f_H(x|\theta_H)$$

Modelos de mezcla

$$f(x) = 0.6 \times \phi(x; 170, 1) + 0.4 \times \phi(x; 180, 1)$$



Un modelo de mezcla finito tiene la forma:

$$f(x) = \pi_1 f_1(x|\theta_1) + \cdots + \pi_H f_H(x|\theta_H)$$

En general

$$f(x) = \int_{\Theta} f(x|\theta) dP(\theta)$$

1 Aspectos preliminares

2 Estimación de un distribución

- Modelo Dirichlet-Multinomial
- Medida de probabilidad aleatoria
- Proceso de Dirichlet: Definición
- Stick-Breaking
- Estimación de una distribución

3 Modelos de mezcla controlados por proceso de Dirichlet

4 Estudio de simulación

5 Aspectos computacionales

Modelo Dirichlet-Multinomial

Sean X_1, \dots, X_n i.i.d. con $\text{Rec}(X_i) = \{1, 2, \dots, k\}$ tales que $\mathbb{P}(X_i = j) = \pi_j$ para $j = 1, 2, \dots, k$.

Si $Y_j := \sum_{i=1}^n \mathbb{1}_{\{X_i=j\}}$ para $j = 1, \dots, k \Rightarrow (Y_1, \dots, Y_k) \sim \text{Multinomial}(\pi_1, \dots, \pi_k)$.

Modelo Dirichlet-Multinomial

Sean X_1, \dots, X_n i.i.d. con $\text{Rec}(X_i) = \{1, 2, \dots, k\}$ tales que $\mathbb{P}(X_i = j) = \pi_j$ para $j = 1, 2, \dots, k$.

Si $Y_j := \sum_{i=1}^n \mathbb{1}_{\{X_i=j\}}$ para $j = 1, \dots, k \Rightarrow (Y_1, \dots, Y_k) \sim \text{Multinomial}(\pi_1, \dots, \pi_k)$.

Distribución de Dirichlet

Su soporte es el conjunto de los vectores de probabilidad de dimensión k , (\mathcal{P}_k) .

$(\pi_1, \dots, \pi_k) \sim \text{Dirichlet}(a_1, \dots, a_k)$, $(a_i > 0 \forall i)$ si:

$$f(\pi_1, \dots, \pi_k | a_1, \dots, a_k) = \frac{\Gamma\left(\sum_{j=1}^k a_j\right)}{\prod_{j=1}^k \Gamma(a_j)} \prod_{j=1}^k \pi_j^{a_j-1} \mathbb{1}_{\{\mathcal{P}_k\}}(\pi_1, \dots, \pi_k)$$

Modelo Dirichlet-Multinomial

Sean X_1, \dots, X_n i.i.d. con $\text{Rec}(X_i) = \{1, 2, \dots, k\}$ tales que $\mathbb{P}(X_i = j) = \pi_j$ para $j = 1, 2, \dots, k$.

Si $Y_j := \sum_{i=1}^n \mathbb{1}_{\{X_i=j\}}$ para $j = 1, \dots, k \Rightarrow (Y_1, \dots, Y_k) \sim \text{Multinomial}(\pi_1, \dots, \pi_k)$.

Distribución de Dirichlet

Su soporte es el conjunto de los vectores de probabilidad de dimensión k , (\mathcal{P}_k) .

$(\pi_1, \dots, \pi_k) \sim \text{Dirichlet}(a_1, \dots, a_k)$, $(a_i > 0 \forall i)$ si:

$$f(\pi_1, \dots, \pi_k | a_1, \dots, a_k) = \frac{\Gamma(\sum_{j=1}^k a_j)}{\prod_{j=1}^k \Gamma(a_j)} \prod_{j=1}^k \pi_j^{a_j-1} \mathbb{1}_{\{\mathcal{P}_k\}}(\pi_1, \dots, \pi_k)$$

- Todas sus marginales π_j se distribuyen Beta

Modelo Dirichlet-Multinomial

Sean X_1, \dots, X_n i.i.d. con $\text{Rec}(X_i) = \{1, 2, \dots, k\}$ tales que $\mathbb{P}(X_i = j) = \pi_j$ para $j = 1, 2, \dots, k$.

Si $Y_j := \sum_{i=1}^n \mathbb{1}_{\{X_i=j\}}$ para $j = 1, \dots, k \Rightarrow (Y_1, \dots, Y_k) \sim \text{Multinomial}(\pi_1, \dots, \pi_k)$.

Distribución de Dirichlet

Su soporte es el conjunto de los vectores de probabilidad de dimensión k , (\mathcal{P}_k) .

$(\pi_1, \dots, \pi_k) \sim \text{Dirichlet}(a_1, \dots, a_k)$, $(a_i > 0 \forall i)$ si:

$$f(\pi_1, \dots, \pi_k | a_1, \dots, a_k) = \frac{\Gamma(\sum_{j=1}^k a_j)}{\prod_{j=1}^k \Gamma(a_j)} \prod_{j=1}^k \pi_j^{a_j-1} \mathbb{1}_{\{\mathcal{P}_k\}}(\pi_1, \dots, \pi_k)$$

- Todas sus marginales π_j se distribuyen Beta
- Es un [modelo conjugado](#). Si se observa $\mathbf{y}_1, \dots, \mathbf{y}_N$ donde $\mathbf{y}_i = (y_{1,i}, \dots, y_{k,i})$

Modelo Dirichlet-Multinomial

Sean X_1, \dots, X_n i.i.d. con $\text{Rec}(X_i) = \{1, 2, \dots, k\}$ tales que $\mathbb{P}(X_i = j) = \pi_j$ para $j = 1, 2, \dots, k$.

Si $Y_j := \sum_{i=1}^n \mathbb{1}_{\{X_i=j\}}$ para $j = 1, \dots, k \Rightarrow (Y_1, \dots, Y_k) \sim \text{Multinomial}(\pi_1, \dots, \pi_k)$.

Distribución de Dirichlet

Su soporte es el conjunto de los vectores de probabilidad de dimensión k , (\mathcal{P}_k) .


$(\pi_1, \dots, \pi_k) \sim \text{Dirichlet}(a_1, \dots, a_k)$, $(a_i > 0 \forall i)$ si:

$$f(\pi_1, \dots, \pi_k | a_1, \dots, a_k) = \frac{\Gamma(\sum_{j=1}^k a_j)}{\prod_{j=1}^k \Gamma(a_j)} \prod_{j=1}^k \pi_j^{a_j-1} \mathbb{1}_{\{\mathcal{P}_k\}}(\pi_1, \dots, \pi_k)$$


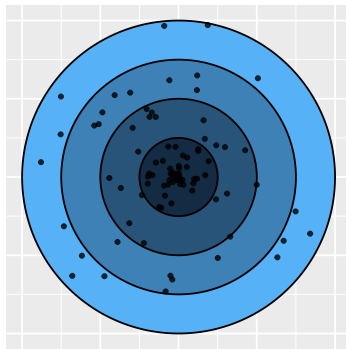
- Todas sus marginales π_j se distribuyen Beta
- Es un [modelo conjugado](#). Si se observa $\mathbf{y}_1, \dots, \mathbf{y}_N$ donde $\mathbf{y}_i = (y_{1,i}, \dots, y_{k,i})$ entonces

$$(\pi_1, \dots, \pi_k) | \mathbf{y}_1, \dots, \mathbf{y}_N \sim \text{Dirichlet}(a_1 + \sum_{i=1}^N y_{1,i}, \dots, a_k + \sum_{i=1}^N y_{k,i})$$



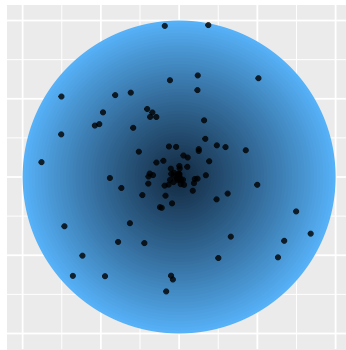

Proceso de Dirichlet



Proceso de Dirichlet



Proceso de Dirichlet



Medida de Probabilidad Aleatoria

Dado un espacio probabilizable $(\mathcal{X}, \mathcal{B}(\mathcal{X}))$ y un espacio de probabilidad $(\Omega, \mathcal{B}(\Omega), \mathbb{P})$, definimos medida de probabilidad aleatoria a la función:


$$\mathcal{P} : \Omega \times \mathcal{B}(\mathcal{X}) \rightarrow [0, 1]$$

tal que:

- Fijado $\omega \in \Omega$, para todo $B \in \mathcal{B}(\mathcal{X})$, el mapeo $B \mapsto \mathcal{P}(\omega, B)$ es una medida de probabilidad sobre el espacio probabilizable $(\mathcal{X}, \mathcal{B}(\mathcal{X}))$
- Fijado $B \in \mathcal{B}(\mathcal{X})$, para todo $\omega \in \Omega$, el mapeo $\omega \mapsto \mathcal{P}(\omega, B)$ es una variable aleatoria que toma valores en $[0, 1]$.


Medida de Probabilidad Aleatoria

- Fijado $\omega \in \Omega$, para todo $B \in \mathcal{B}(\mathcal{X})$, el mapeo $B \mapsto \mathcal{P}(\omega, B)$ es una medida de probabilidad sobre el espacio probabilizable $(\mathcal{X}, \mathcal{B}(\mathcal{X}))$
- Fijado $B \in \mathcal{B}(\mathcal{X})$, para todo $\omega \in \Omega$, el mapeo $\omega \mapsto \mathcal{P}(\omega, B)$ es una variable aleatoria que toma valores en $[0, 1]$.



Medida de Probabilidad Aleatoria

- Fijado $\omega \in \Omega$, para todo $B \in \mathcal{B}(\mathcal{X})$, el mapeo $B \mapsto \mathcal{P}(\omega, B)$ es una medida de probabilidad sobre el espacio probabilizable $(\mathcal{X}, \mathcal{B}(\mathcal{X}))$
- Fijado $B \in \mathcal{B}(\mathcal{X})$, para todo $\omega \in \Omega$, el mapeo $\omega \mapsto \mathcal{P}(\omega, B)$ es una variable aleatoria que toma valores en $[0, 1]$.



Proceso de Dirichlet

Sea $(\Omega, \mathcal{B}(\mathbb{R}), \mathbb{P})$ un espacio de probabilidad, \mathcal{P} una medida de probabilidad aleatoria sobre $(\Omega, \mathcal{B}(\mathbb{R}), \mathbb{P})$.

Proceso de Dirichlet

Sea $(\Omega, \mathcal{B}(\mathbb{R}), \mathbb{P})$ un espacio de probabilidad, \mathcal{P} una medida de probabilidad aleatoria sobre $(\Omega, \mathcal{B}(\mathbb{R}), \mathbb{P})$.

Diremos que \mathcal{P} está definida por un proceso de Dirichlet de parámetros α y G_0 si para cualquier partición medible de \mathbb{R} de la forma $\mathcal{A} = (A_1, \dots, A_k)$, se cumple que:

$$\mathcal{P}(\mathcal{A}) = \left(\mathcal{P}(A_1), \mathcal{P}(A_2), \dots, \mathcal{P}(A_k) \right) \sim \text{Dirichlet}(\alpha G_0(A_1), \dots, \alpha G_0(A_k))$$

Proceso de Dirichlet

Sea $(\Omega, \mathcal{B}(\mathbb{R}), \mathbb{P})$ un espacio de probabilidad, \mathcal{P} una medida de probabilidad aleatoria sobre $(\Omega, \mathcal{B}(\mathbb{R}), \mathbb{P})$.

Diremos que \mathcal{P} está definida por un proceso de Dirichlet de parámetros α y G_0 si para cualquier partición medible de \mathbb{R} de la forma $\mathcal{A} = (A_1, \dots, A_k)$, se cumple que:

$$\mathcal{P}(\mathcal{A}) = \left(\mathcal{P}(A_1), \mathcal{P}(A_2), \dots, \mathcal{P}(A_k) \right) \sim \text{Dirichlet}(\alpha G_0(A_1), \dots, \alpha G_0(A_k))$$

y lo notaremos: $\mathcal{P} \sim DP(\alpha, G_0)$, donde $\alpha > 0$ es un parámetro de precisión y G_0 es una medida de probabilidad base.


Stick-Breaking

En [Sethuraman, 1994] se prueba que si \mathcal{P} es un proceso de Dirichlet con parámetros (α, G_0) , entonces, se puede escribir de la forma:


$$\mathcal{P} = \sum_{k=1}^{\infty} \pi_k \delta_{\theta_k} \quad (1)$$

donde δ_x es la *Delta de Dirac*

- $\theta_1, \theta_2, \dots \sim G_0$
- $\pi_1, \pi_2, \dots \sim \text{Stick}(\alpha)$



Dos realizaciones de stick breaking



Estimación de una distribución

Modelo para los datos:

$$X_1, \dots, X_n \stackrel{\text{ind}}{\sim} \mathcal{P}$$

(Una realización de una M.P.A.)

Estimación de una distribución

Modelo para los datos:

$$X_1, \dots, X_n \stackrel{\text{ind}}{\sim} \mathcal{P}$$

(Una realización de una M.P.A.)

Distribución previa:

$$\mathcal{P} \sim DP(\alpha, G_0)$$

Estimación de una distribución

Modelo para los datos:

$$X_1, \dots, X_n \stackrel{\text{ind}}{\sim} \mathcal{P} \quad (\text{Una realización de una M.P.A.})$$

Distribución previa:

$$\mathcal{P} \sim DP(\alpha, G_0)$$

Distribución posterior:

$$\mathcal{P} | \{X_1, \dots, X_n\} \sim DP \left(\alpha + n, \frac{\alpha}{\alpha + n} G_0 + \frac{1}{\alpha + n} \sum_{i=1}^n \delta_{X_i} \right)$$

[Ferguson, 1973]

Estimación de una distribución

Tomando $\mathcal{A} = \{A_1, \dots, A_k\}$ una partición cualquiera, se tiene que

$$\mathcal{P}(\mathcal{A})|X_1, \dots, X_n \sim \text{Dirichlet} \left(\alpha \cdot G_0(A_1) + \sum_{i=1}^n \mathbb{1}_{\{X_i \in A_1\}}, \dots, \alpha \cdot G_0(A_k) + \sum_{i=1}^n \mathbb{1}_{\{X_i \in A_k\}} \right)$$

Si $\mathcal{A} = \{A_x, A_x^c\}$ con $A_x = (-\infty, x]$, entonces $\mathcal{P}(A_x) = F(x)$:

$$F(x)|X_1, \dots, X_n \sim \text{Beta} \left(\alpha G_0(A_x) + nF_n(x), \alpha(1 - G_0(A_x)) + n(1 - F_n(x)) \right)$$


Estimación de una distribución

- $\mathbb{E}(F(x)|X_1, \dots, X_n) = \left(\frac{\alpha}{\alpha + n}\right) G_0(A_x) + \left(\frac{n}{\alpha + n}\right) F_n(x)$
- $Var(F(x)|X_1, \dots, X_n) = \frac{(\alpha G_0(A_x) + n F_n(x))(1 - \alpha G_0(A_x) - n F_n(x))}{(\alpha + n)^2}$

Estimación de una distribución

- $\mathbb{E}(F(x)|X_1, \dots, X_n) = \left(\frac{\alpha}{\alpha + n}\right) G_0(A_x) + \left(\frac{n}{\alpha + n}\right) F_n(x)$
- $\text{Var}(F(x)|X_1, \dots, X_n) = \frac{(\alpha G_0(A_x) + (\alpha G_0(A_x^c) + n F_n(x))}{(\alpha + n)^2(\alpha + n + 1)}$

Esperanza posterior de la distribución



1 Aspectos preliminares

2 Estimación de un distribución

3 Modelos de mezcla controlados por proceso de Dirichlet

- Formulación del modelo
- Implementación del estimador

4 Estudio de simulación

5 Aspectos computacionales

Modelos de mezcla controlados por DP

Si f está dada por un DPMM entonces:

$$\begin{aligned} f(x) &= \int f_{\theta}(x|\theta) dP(\theta) \\ &= \sum_h \pi_h f_{\theta}(x|\theta_h) \end{aligned}$$

donde $P = \sum_h \pi_h \delta_{\theta_h}$ es un proceso de Dirichlet.

Modelos de mezcla controlados por DP

Si f está dada por un DPMM entonces:

$$\begin{aligned} f(x) &= \int f_{\theta}(x|\theta) dP(\theta) \\ &= \sum_h \pi_h f_{\theta}(x|\theta_h) \end{aligned}$$

donde $P = \sum_h \pi_h \delta_{\theta_h}$ es un proceso de Dirichlet.

Esta formulación es equivalente a plantear el siguiente modelo jerárquico:

$$\left. \begin{aligned} X_i &\overset{\text{ind}}{\sim} F(\cdot|\theta_i) \\ \theta_i &\overset{\text{ind}}{\sim} \mathcal{P} = \sum_{h=1}^{\infty} \pi_h \delta_{\theta_h^*} \\ \left. \begin{aligned} \theta_h^* &\overset{\text{ind}}{\sim} G_0 \\ \pi_h &\sim \text{Stick}(\alpha) \end{aligned} \right\} \mathcal{P} &\sim DP(\alpha, G_0) \end{aligned} \right\}$$


[Gelman et al., 2013], [Niemi, 2017]

Analogía con los estimadores por núcleo

Los estimadores por núcleo

$$f \approx \hat{f} = \sum_{i=1}^n \frac{1}{n} K_{h, x_i}(x)$$


Estimador por núcleos



En nuestro caso:

$$f \approx \hat{f} = \sum_{h=1}^{\infty} \pi_h K_{\theta_h}(x)$$

Mezcla controlada por DP



Modelos de mezcla DP con distribución normal

$$\left. \begin{aligned} X_i &\overset{\text{ind}}{\sim} F(\cdot|\theta_i) \\ \theta_i &\overset{\text{ind}}{\sim} \mathcal{P} = \sum_{h=1}^{\infty} \pi_h \delta_{\theta_h^*} \\ \theta_h^* &\overset{\text{ind}}{\sim} G_0 \\ \pi_h &\sim \text{Stick}(\alpha) \end{aligned} \right\} \mathcal{P} \sim DP(\alpha, G_0)$$

Modelos de mezcla DP con distribución normal

$$\left. \begin{aligned} X_i &\stackrel{\text{ind}}{\sim} F(\cdot|\theta_i) \\ \theta_i &\stackrel{\text{ind}}{\sim} \mathcal{P} = \sum_{h=1}^{\infty} \pi_h \delta_{\theta_h^*} \\ \theta_h^* &\stackrel{\text{ind}}{\sim} G_0 \\ \pi_h &\sim \text{Stick}(\alpha) \end{aligned} \right\} \mathcal{P} \sim DP(\alpha, G_0)$$


$$\begin{aligned} X_i &\stackrel{\text{ind}}{\sim} \mathcal{N}(\mu_i, \sigma_i^2) \\ (\mu_i, \sigma_i^2) &\sim \mathcal{P} = \sum_{h=1}^{\infty} \pi_h \delta_{(\mu_h^*, \sigma_h^{2*})} \\ (\mu_h^*, \sigma_h^{2*}) &\sim \underbrace{N(\mu|m, \frac{1}{k}\sigma^2) \times IG(\sigma^2|\nu, \psi)}_{G_0(\mu, \sigma)} \\ \pi_h &\sim \text{Stick}(\alpha) \\ m \in \mathbb{R}, \alpha, k, \nu, \psi &\in \mathbb{R}^+ \end{aligned}$$

Modelos de mezcla DP con distribución normal

$$\left. \begin{aligned} X_i &\stackrel{\text{ind}}{\sim} F(\cdot|\theta_i) \\ \theta_i &\stackrel{\text{ind}}{\sim} \mathcal{P} = \sum_{h=1}^{\infty} \pi_h \delta_{\theta_h^*} \\ \theta_h^* &\stackrel{\text{ind}}{\sim} G_0 \\ \pi_h &\sim \text{Stick}(\alpha) \end{aligned} \right\} \mathcal{P} \sim DP(\alpha, G_0)$$

Stick-breaking bidimensional con base G_0

$$\begin{aligned} X_i &\stackrel{\text{ind}}{\sim} \mathcal{N}(\mu_i, \sigma_i^2) \\ (\mu_i, \sigma_i^2) &\sim \mathcal{P} = \sum_{h=1}^{\infty} \pi_h \delta_{(\mu_h^*, \sigma_h^{2*})} \\ (\mu_h^*, \sigma_h^{2*}) &\sim \underbrace{N(\mu|m, \frac{1}{k}\sigma^2) \times IG(\sigma^2|\nu, \psi)}_{G_0(\mu, \sigma)} \\ \pi_h &\sim \text{Stick}(\alpha) \\ m \in \mathbb{R}, \alpha, k, \nu, \psi &\in \mathbb{R}^+ \end{aligned}$$



Modelos de mezcla DP con distribución normal

$$\left. \begin{aligned} X_i &\overset{\text{ind}}{\sim} F(\cdot|\theta_i) \\ \theta_i &\overset{\text{ind}}{\sim} \mathcal{P} = \sum_{h=1}^{\infty} \pi_h \delta_{\theta_h^*} \\ \theta_h^* &\overset{\text{ind}}{\sim} G_0 \\ \pi_h &\sim \text{Stick}(\alpha) \end{aligned} \right\} \mathcal{P} \sim DP(\alpha, G_0)$$

$$\begin{aligned} X_i &\overset{\text{ind}}{\sim} \mathcal{N}(\mu_i, \sigma_i^2) \\ (\mu_i, \sigma_i^2) &\sim \mathcal{P} = \sum_{h=1}^{\infty} \pi_h \delta_{(\mu_h^*, \sigma_h^{2*})} \\ (\mu_h^*, \sigma_h^{2*}) &\sim \underbrace{N(m, \frac{1}{k}\sigma^2) \times IG(\nu, \psi)}_{G_0(\mu, \sigma)} \\ \pi_h &\sim \text{Stick}(\alpha) \end{aligned}$$

$$X_i \overset{\text{ind}}{\sim} \mathcal{N}(\mu_i, \sigma_i^2)$$

$$m \in \mathbb{R}, \alpha, k, \nu, \psi \in \mathbb{R}^+$$

Modelos de mezcla DP con distribución normal


$$\left. \begin{aligned} X_i &\overset{\text{ind}}{\sim} F(\cdot|\theta_i) \\ \theta_i &\overset{\text{ind}}{\sim} \mathcal{P} = \sum_{h=1}^{\infty} \pi_h \delta_{\theta_h^*} \\ \theta_h^* &\overset{\text{ind}}{\sim} G_0 \\ \pi_h &\sim \text{Stick}(\alpha) \end{aligned} \right\} \mathcal{P} \sim DP(\alpha, G_0)$$

$$\begin{aligned} X_i &\overset{\text{ind}}{\sim} \mathcal{N}(\mu_i, \sigma_i^2) \\ (\mu_i, \sigma_i^2) &\sim \mathcal{P} = \sum_{h=1}^{\infty} \pi_h \delta_{(\mu_h^*, \sigma_h^{2*})} \\ (\mu_h^*, \sigma_h^{2*}) &\sim \underbrace{N\left(m, \frac{1}{k}\sigma^2\right) \times IG(\nu, \psi)}_{G_0(\mu, \sigma)} \\ \pi_h &\sim \text{Stick}(\alpha) \\ m \in \mathbb{R}, \alpha, k, \nu, \psi &\in \mathbb{R}^+ \end{aligned}$$

$$\begin{aligned} X_i &\overset{\text{ind}}{\sim} \mathcal{N}(\mu_i, \sigma_i^2) \\ (\mu_i, \sigma_i^2) &\sim \mathcal{P} = \sum_{h=1}^H \pi_h \delta_{(\mu_h^*, \sigma_h^{2*})} \end{aligned}$$

Modelos de mezcla DP con distribución normal

$$\left. \begin{aligned} X_i &\stackrel{\text{ind}}{\sim} F(\cdot | \theta_i) \\ \theta_i &\stackrel{\text{ind}}{\sim} \mathcal{P} = \sum_{h=1}^{\infty} \pi_h \delta_{\theta_h^*} \\ \theta_h^* &\stackrel{\text{ind}}{\sim} G_0 \\ \pi_h &\sim \text{Stick}(\alpha) \end{aligned} \right\} \mathcal{P} \sim DP(\alpha, G_0)$$




$$X_i \stackrel{\text{ind}}{\sim} \mathcal{N}(\mu_i, \sigma_i^2)$$

$$(\mu_i, \sigma_i^2) \sim \mathcal{P} = \underbrace{\sum_{h=1}^H \pi_h \delta_{(\mu_h^*, \sigma_h^{2*})}}_{\text{Distribución discreta}}$$

Modelos de mezcla DP con distribución normal


$$\left. \begin{aligned} X_i &\stackrel{\text{ind}}{\sim} F(\cdot | \theta_i) \\ \theta_i &\stackrel{\text{ind}}{\sim} \mathcal{P} = \sum_{h=1}^{\infty} \pi_h \delta_{\theta_h^*} \\ \theta_h^* &\stackrel{\text{ind}}{\sim} G_0 \\ \pi_h &\sim \text{Stick}(\alpha) \end{aligned} \right\} \mathcal{P} \sim DP(\alpha, G_0)$$



$$\begin{aligned} X_i &\stackrel{\text{ind}}{\sim} \mathcal{N}(\mu_i, \sigma_i^2) \\ (\mu_i, \sigma_i^2) &\sim \mathcal{P} = \sum_{h=1}^H \pi_h \delta_{(\mu_h^*, \sigma_h^{2*})} \\ \xi_i &\sim \text{Cat}(\{1, \dots, H\}, \boldsymbol{\pi}) \end{aligned}$$

Modelos de mezcla DP con distribución normal

$$\left. \begin{aligned} X_i &\stackrel{\text{ind}}{\sim} F(\cdot | \theta_i) \\ \theta_i &\stackrel{\text{ind}}{\sim} \mathcal{P} = \sum_{h=1}^{\infty} \pi_h \delta_{\theta_h^*} \\ \theta_h^* &\stackrel{\text{ind}}{\sim} G_0 \\ \pi_h &\sim \text{Stick}(\alpha) \end{aligned} \right\} \mathcal{P} \sim DP(\alpha, G_0)$$



$$X_i \stackrel{\text{ind}}{\sim} \mathcal{N}(\mu_i, \sigma_i^2)$$

$$(\mu_i, \sigma_i^2) \sim \mathcal{P} = \sum_{h=1}^H \pi_h \delta_{(\mu_h^*, \sigma_h^{2*})}$$

$$\xi_i \sim \text{Cat}(\{1, \dots, H\}, \boldsymbol{\pi})$$

$$(\mu_i, \sigma_i^2) | \{\xi_i = h\} \stackrel{\text{cs}}{=} (\mu_h^*, \sigma_h^{2*})$$

El modelo final

$$\left. \begin{aligned} X_i &\stackrel{\text{ind}}{\sim} F(\cdot|\theta_i) \\ \theta_i &\stackrel{\text{ind}}{\sim} \mathcal{P} = \sum_{h=1}^{\infty} \pi_h \delta_{\theta_h^*} \\ \theta_h^* &\stackrel{\text{ind}}{\sim} G_0 \\ \pi_h &\sim \text{Stick}(\alpha) \end{aligned} \right\} \mathcal{P} \sim DP(\alpha, G_0)$$

$$\begin{aligned} X_i &\stackrel{\text{ind}}{\sim} \mathcal{N}(\mu_i, \sigma_i^2) \\ (\mu_i, \sigma_i^2) &\sim \mathcal{P} = \sum_{h=1}^{\infty} \pi_h \delta_{(\mu_h^*, \sigma_h^{2*})} \\ (\mu_h^*, \sigma_h^{2*}) &\sim \underbrace{N(\mu|m, \frac{1}{k}\sigma^2) \times IG(\sigma^2|\nu, \psi)}_{G_0(\mu, \sigma)} \\ \pi_h &\sim \text{Stick}(\alpha) \\ m \in \mathbb{R}, \alpha, k, \nu, \psi &\in \mathbb{R}^+ \end{aligned}$$

$$\begin{aligned} X_i &\stackrel{\text{ind}}{\sim} \sum_{h=1}^H \pi_h N(\mu_h^*, \sigma_h^{2*}) \\ (\mu_h^*, \sigma_h^{2*}) &\sim N(m, \frac{1}{k}\sigma^2) \times IG(\nu, \psi) \\ \pi_h &\sim \text{Stick}(\alpha) \\ m \in \mathbb{R}, \alpha, k, \nu, \psi &\in \mathbb{R}^+ \end{aligned}$$

Obtención de estimadores

$$X_i \stackrel{\text{ind}}{\sim} \sum_{h=1}^H \pi_h N(\mu_h^*, \sigma_h^{2*})$$

La densidad queda determinada por los parámetros $\{\pi_h, \mu_h^*, \sigma_h^{2*}\}_{h=1, \dots, H}$

Obtención de estimadores

$$X_i \stackrel{ind}{\sim} \sum_{h=1}^H \pi_h N(\mu_h^*, \sigma_h^{2*})$$

La densidad queda determinada por los parámetros $\{\pi_h, \mu_h^*, \sigma_h^{2*}\}_{h=1, \dots, H}$

El algoritmo de Gibbs devuelve:

Iter 1	Iter 2	Iter 3	...	Iter m
$\pi_{1,1}$	$\pi_{1,2}$	$\pi_{1,3}$...	$\pi_{1,m}$
$\mu_{1,1}$	$\mu_{1,2}$	$\mu_{1,3}$...	$\mu_{1,m}$
$\sigma_{1,1}$	$\sigma_{1,2}$	$\sigma_{1,3}$...	$\sigma_{1,m}$
\vdots	\vdots	\vdots	\vdots	\vdots
$\pi_{H,1}$	$\pi_{H,2}$	$\pi_{H,3}$...	$\pi_{H,m}$
$\mu_{H,1}$	$\mu_{H,2}$	$\mu_{H,3}$...	$\mu_{H,m}$
$\sigma_{H,1}$	$\sigma_{H,2}$	$\sigma_{H,3}$...	$\sigma_{H,m}$

Obtención de estimadores

$$X_i \stackrel{ind}{\sim} \sum_{h=1}^H \pi_h N(\mu_h^*, \sigma_h^{2*})$$

La densidad queda determinada por los parámetros $\{\pi_h, \mu_h^*, \sigma_h^{2*}\}_{h=1, \dots, H}$

El algoritmo de Gibbs devuelve:

Iter 1	Iter 2	Iter 3	...	Iter m
$\pi_{1,1}$	$\pi_{1,2}$	$\pi_{1,3}$...	$\pi_{1,m}$
$\mu_{1,1}$	$\mu_{1,2}$	$\mu_{1,3}$...	$\mu_{1,m}$
$\sigma_{1,1}$	$\sigma_{1,2}$	$\sigma_{1,3}$...	$\sigma_{1,m}$
\vdots	\vdots	\vdots	\vdots	\vdots
$\pi_{H,1}$	$\pi_{H,2}$	$\pi_{H,3}$...	$\pi_{H,m}$
$\mu_{H,1}$	$\mu_{H,2}$	$\mu_{H,3}$...	$\mu_{H,m}$
$\sigma_{H,1}$	$\sigma_{H,2}$	$\sigma_{H,3}$...	$\sigma_{H,m}$

En cada iteración:

$$\hat{f}(x)^{(k)} = \sum_{h=1}^H \pi_h^{(k)} \phi(x; \mu_h^{(k)}, \sigma_h^{(k)})$$

Obtención de estimadores

$$X_i \stackrel{\text{ind}}{\sim} \sum_{h=1}^H \pi_h N(\mu_h^*, \sigma_h^{2*})$$

La densidad queda determinada por los parámetros $\{\pi_h, \mu_h^*, \sigma_h^{2*}\}_{h=1, \dots, H}$

El algoritmo de Gibbs devuelve:

Iter 1	Iter 2	Iter 3	...	Iter m
$\pi_{1,1}$	$\pi_{1,2}$	$\pi_{1,3}$...	$\pi_{1,m}$
$\mu_{1,1}$	$\mu_{1,2}$	$\mu_{1,3}$...	$\mu_{1,m}$
$\sigma_{1,1}$	$\sigma_{1,2}$	$\sigma_{1,3}$...	$\sigma_{1,m}$
\vdots	\vdots	\vdots	\vdots	\vdots
$\pi_{H,1}$	$\pi_{H,2}$	$\pi_{H,3}$...	$\pi_{H,m}$
$\mu_{H,1}$	$\mu_{H,2}$	$\mu_{H,3}$...	$\mu_{H,m}$
$\sigma_{H,1}$	$\sigma_{H,2}$	$\sigma_{H,3}$...	$\sigma_{H,m}$

En cada iteración:

$$\hat{f}(x)^{(k)} = \sum_{h=1}^H \pi_h^{(k)} \phi(x; \mu_h^{(k)}, \sigma_h^{(k)})$$

Un estimador puntual:

$$\hat{f}(x) = \frac{1}{m} \sum_{k=1}^m \hat{f}(x)^{(k)}$$

Obtención de estimadores

$$X_i \stackrel{\text{ind}}{\sim} \sum_{h=1}^H \pi_h N(\mu_h^*, \sigma_h^{2*})$$

La densidad queda determinada por los parámetros $\{\pi_h, \mu_h^*, \sigma_h^{2*}\}_{h=1, \dots, H}$

El algoritmo de Gibbs devuelve:

Iter 1	Iter 2	Iter 3	...	Iter m
$\pi_{1,1}$	$\pi_{1,2}$	$\pi_{1,3}$...	$\pi_{1,m}$
$\mu_{1,1}$	$\mu_{1,2}$	$\mu_{1,3}$...	$\mu_{1,m}$
$\sigma_{1,1}$	$\sigma_{1,2}$	$\sigma_{1,3}$...	$\sigma_{1,m}$
\vdots	\vdots	\vdots	\vdots	\vdots
$\pi_{H,1}$	$\pi_{H,2}$	$\pi_{H,3}$...	$\pi_{H,m}$
$\mu_{H,1}$	$\mu_{H,2}$	$\mu_{H,3}$...	$\mu_{H,m}$
$\sigma_{H,1}$	$\sigma_{H,2}$	$\sigma_{H,3}$...	$\sigma_{H,m}$

En cada iteración:

$$\hat{f}(x)^{(k)} = \sum_{h=1}^H \pi_h^{(k)} \phi(x; \mu_h^{(k)}, \sigma_h^{(k)})$$

Un estimador puntual:

$$\hat{f}(x) = \frac{1}{m} \sum_{k=1}^m \hat{f}(x)^{(k)}$$

Si en lugar de promediar, se toman percentiles, se obtiene un intervalo de credibilidad.

1 Aspectos preliminares

2 Estimación de un distribución

3 Modelos de mezcla controlados por proceso de Dirichlet

4 Estudio de simulación

5 Aspectos computacionales

Estudio de simulación

Caso 1: χ_{10}^2 : Distribución χ^2 con 10 grados de libertad.

Caso 2: Claw: $f(x) = \frac{1}{2}\phi(x; 0, 1) + \frac{1}{10} \sum_{j=0}^4 \phi(x; \frac{j}{2} - 1, \frac{1}{10})$


Caso 3: Mix₁: $f(x) = \frac{1}{3}\phi(x; -4, 0.1) + \frac{1}{3}\phi(x; -2, 0.5) + \frac{1}{3}\phi(x; 2, 1)$

Caso 4: Mix₂: $f(x) = \frac{1}{2}\mathbb{1}_{\{-2, -1\}}(x) + \frac{1}{2}\mathbb{1}_{\{[1, 2]\}}(x)$


[Bourel & Cugliari, 2018]

$$\text{MISE}(\hat{f}) = \mathbb{E} \left[\int_{\mathbb{R}} (\hat{f}(x) - f(x))^2 dx \right]$$


Distribuciones a simular




(a) χ^2_{10}



(b) Claw

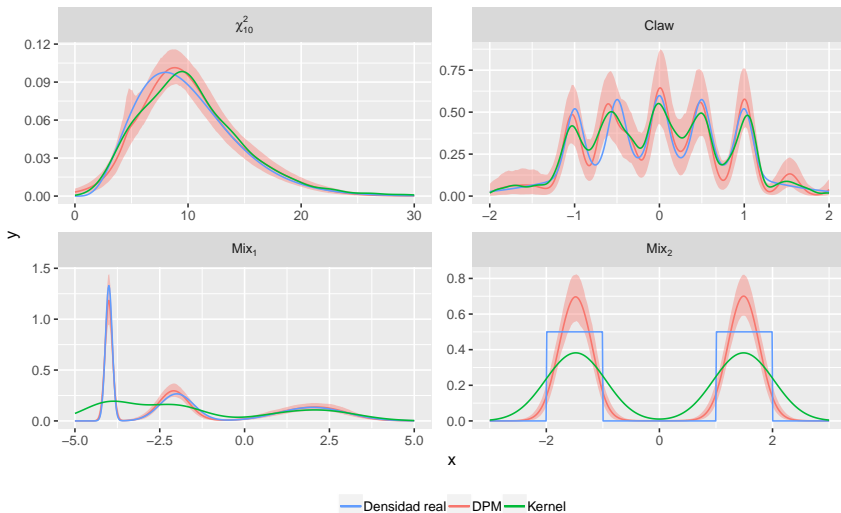


(c) Mix₁



(d) Mix₂


Estimaciones obtenidas




MISE

	DPM	Kernel
χ^2_{10}	8.53E-04	9.42E-04
Claw	1.52E-02	1.44E-02
Mix ₁	5.71E-03	2.94E-02
Mix ₂	5.32E-02	2.75E-02

Cuadro: MISE en cada uno de los casos



(a) Diferencia relativa entre el error de DPM y Kernel (DPM-Ker)/Ker



(b) Gráficos de caja de los valores del error cuadrático integrado

1 Aspectos preliminares

2 Estimación de un distribución


3 Modelos de mezcla controlados por proceso de Dirichlet

4 Estudio de simulación

5 Aspectos computacionales


Un ejemplo

$$f(x) = \frac{1}{3}\phi(x; -4, 0.1) + \frac{1}{3}\phi(x; -2, 0.5) + \frac{1}{3}\phi(x; 2, 1)$$



Un ejemplo


$$f(x) = \frac{1}{3}\phi(x; -4, 0.1) + \frac{1}{3}\phi(x; -2, 0.5) + \frac{1}{3}\phi(x; 2, 1)$$



Parámetros de la distinta distribución base


Caso 1	$\alpha = 1$	$m = -1$	$k = 1$	$\nu = 0.1$	$\psi = 0.1$
Caso 2	$\alpha = 1$	$m = -1$	$k = 0.01$	$\nu = 0.1$	$\psi = 0.1$
Caso 3	$\alpha = 1$	$m = -1$	$k = 20$	$\nu = 1000$	$\psi = 10$
Caso 4	$\alpha = 1$	$m = -1$	$k = 0.1$	$\nu = 1000$	$\psi = 10$

Cuadro: Parámetros de la distribución base usados




Estimador kernel


El método de estimación por kernel al tener ancho de banda fijo no produce un buen resultado.



Componentes de la mezcla



La estimación en distintas iteraciones



Resumen y conclusiones

- Se quiso estimar la distribución de una v.a. con recorrido $\{1, 2, \dots, k\}$
⇒ Modelo Dirichlet-Multinomial

Resumen y conclusiones

- Se quiso estimar la distribución de una v.a. con recorrido $\{1, 2, \dots, k\}$
⇒ Modelo Dirichlet-Multinomial
- Extensión a variables con recorrido infinito.
⇒ Los datos se distribuyen según una medida de probabilidad aleatoria, proceso de Dirichlet como previa y posterior. Modelo conjugado.

Resumen y conclusiones

- Se quiso estimar la distribución de una v.a. con recorrido $\{1, 2, \dots, k\}$
⇒ Modelo Dirichlet-Multinomial
- Extensión a variables con recorrido infinito.
⇒ Los datos se distribuyen según una medida de probabilidad aleatoria, proceso de Dirichlet como previa y posterior. Modelo conjugado.
[Limitante](#): Estimación discreta
- Variables aleatorias con densidad
⇒ Modelos de mezcla controlados por el proceso de Dirichlet.

Resumen y conclusiones

- Se quiso estimar la distribución de una v.a. con recorrido $\{1, 2, \dots, k\}$
⇒ Modelo Dirichlet-Multinomial
- Extensión a variables con recorrido infinito.
⇒ Los datos se distribuyen según una medida de probabilidad aleatoria, proceso de Dirichlet como previa y posterior. Modelo conjugado.
Limitante: Estimación discreta
- Variables aleatorias con densidad
⇒ Modelos de mezcla controlados por el proceso de Dirichlet.
- Comparado con el estimador por núcleos:
 - Tiene un desempeño aceptable (MISE).
 - Permite obtener bandas de credibilidad.
 - Es más costoso en tiempo computacional.

Trabajo a futuro

- Extender la estimación al caso multidimensional. Para ello considerar G_0 como Normal multivariada - Inversa Wishart.
- Complejizar el estudio de simulación, variando el tamaño de muestra n .
- Investigar otras posibilidades para $F(\cdot|\theta_i)$ que no sean la distribución normal.
- Asignar una distribución previa a los parámetros de la medida base. (Implementación en **DPpackage**).
- En lugar de promediar iteraciones, tomar la curva “más profunda” en el sentido de alguna función de profundidad.
- Uso de esta técnica en clustering a través de las variables latentes.

Referencias



Bourel, M. and Cugliari, J. (2018).
Bagging of density estimators.
[arXiv preprint arXiv:1808.03447](https://arxiv.org/abs/1808.03447).



Ferguson, T. S. (1973).
A bayesian analysis of some nonparametric problems.
[The annals of statistics](#), pages 209–230.



Gelman, A., Stern, H. S., Carlin, J. B., Dunson, D. B., Vehtari, A., and Rubin, D. B. (2013).
[Bayesian data analysis](#).
Chapman and Hall/CRC.



Niemi, J. (2017).
Bayesian nonparametrics.
<http://www.jarad.me/courses/stat615/slides/Nonparametrics/nonparametrics.pdf>.



Sethuraman, J. (1994).
A constructive definition of dirichlet priors.
[Statistica sinica](#), pages 639–650.

Agradecimientos

¡Muchas gracias!

Estimación de densidades mediante modelos de mezcla controlados por el proceso de Dirichlet

Estudiantes:

MANUEL HERNÁNDEZ BANADIK
MARIO SIERRA GOLOMBIEVSKI

Tutor:


IGNACIO ALVAREZ-CASTRO



2 de julio de 2019

Monitoreo de convergencia

Por cuestiones de identificabilidad el monitoreo no se hace a nivel de cada parámetro. Los parámetros pueden *intercambiar sus índices* a lo largo de las iteraciones sin que esto implique un problema de convergencia:



Para monitorear la convergencia podemos monitorear la convergencia puntual de cada cadena de estimadores evaluado en una grilla de puntos, en este caso $\{x = -4, x = 2, x = 0, x = 1.5\}$

